

Опис проблема

Овај рад истражује проблем аутоматске детекције лажних текстуалних порука на енглеском језику. Лажне и нежељене поруке представљају значајан безбедносни проблем јер могу довести до крађе личних података, финансијских превара и ширења злонамерног садржаја. Циљ рада је развој модела који на основу садржаја текстуалне поруке одређује да ли је порука легитимна (*ham*) или нежељена (*spam*). За решавање овог проблема коришћена је енкодер трансформер архитектура, која омогућава ефикасно разумевање контекста и семантике текста и постиже високу тачност у класификацији текстуалних порука.

Скуп података

За овај рад користиће се скуп података *MENTHOS-dataset-spam*, који је доступан на платформи *Hugging Face*: <https://huggingface.co/datasets/LHRS-UM-FERI/MENTHOS-dataset-spam> Скуп података садржи око 87.000 текстуалних порука подељених на тренинг, валидациони и тест подскуп. Тренинг подскуп садржи 60.982 примера, валидациони 13.166, а тест 13.128. Сваки пример садржи текст поруке (*text*) и бинарну лабелу (*label*), где 0 означава легитимну поруку (*ham*), а 1 нежељену/*spam* поруку. Подаци су формирани спајањем јавно доступних извора *SMS* и *email spam* порука, а сваки подскуп је уравнотежен између две класе, чиме је погодан за бинарну класификацију.

Методе за решавање проблема

Проблем детекције *spam SMS* порука решава се коришћењем трансформер архитектуре засноване на енкодеру. Улазни текст, који представља садржај *SMS* поруке, прво се токенизује, а затим прослеђује енкодеру који моделује значење речи у контексту. На излазу енкодера додаје се класификациони слој који доноси коначну одлуку да ли је у питању легитимна (*ham*) или нежељена (*spam*) порука. Модел се тренира коришћењем *cross-entropy* функције губитка, а успешност модела процењује се на основу тачности и *F1* резултата.

Опис примењених техника

1. **Encoder трансформер архитектура** За класификацију порука коришћена је енкодер трансформер архитектура (само енкодерски део, без декодера). За разлику од пуног *encoder-decoder* трансформатора, овај модел кроз механизам self-attention моделује односе између свих токена у поруци и гради контекстуалну репрезентацију текста. Архитектура је имплементирана од нуле и обухвата уграђивања токена (*embeddings*), позиционо кодирање, блокове са вишеглавастом пажњом (*multi-head self-attention*), *feed-forward* мрежу и нормализацију слојева.
2. **Тренинг од нуле** Уместо коришћења унапред тренираног модела и fine-tuning приступа, модел се тренира од нуле. Параметри се насумично иницијализују (*Xavier* иницијализација) и уче искључиво на скупу *MENTHOS-dataset-spam* за задатак бинарне класификације *ham / spam*. Платформа *Hugging Face* користи се само за преузимање скупа података, а не за учитавање унапред тренираних тежина модела.
3. **Токенизација** Улазни текст се пре обраде у моделу преводи у нумерички облик поступком токенизације. Коришћен је *WordLevel* токенизатор трениран од нуле на тренинг делу скупа података, уз *Whitespace* поделу и специјалне токене [UNK], [PAD], [SOS] и [EOS].
4. **Класификациони слој (classification head)** На излаз енкодера примењује се *mean pooling* преко токена који нису *padding*, а затим линеарни класификациони слој са две излазне класе. Модел производи *logits* за класе *ham* (0) и *spam* (1). Коначна одлука доноси се избором класе са највећом вредношћу (*argmax*). Приликом инференције *logits* се кроз *softmax* функцију преводи у вероватноће, чиме се добија мера поверења модела у предвиђање.

5. **Функција губитка (cross-entropy)** Модел се оптимизује минимизацијом *cross-entropy* функције губитка (унакрсна ентропија), која је стандардна за вишекласну и бинарну класификацију. Она кажњава одступање између предвиђене расподеле вероватноћа и праве лабеле, чиме се параметри модела ажурирају у правцу тачније класификације.
6. **Оптимизација и регуларизација** Тренинг користи оптимизатор AdamW са: стопом учења (learning rate) 3×10^{-4} ; weight decay (0.01) ради смањења претераног прилагођавања (overfitting); dropout регуларизацијом унутар енкодер блокова. Тренинг траје 15 епоха, са величином батча 64 (евалуација са батчем 128).
7. **Евалуација и избор најбољег модела** **Успешност модела мери се следећим метрикама:** Accuracy (тачност), односно удео исправно класификованих порука; Precision (прецизност), тј. колико је предвиђених spam порука заиста spam; Recall (одзив), односно колико је стварних spam порука исправно откривено; F1-score, хармонијска средина precision-а и recall-а. Метрике се рачунају на валидационом скупу након сваке епохе. Као критеријум за избор најбољег модела користи се F1 резултат, јер добро одражава баланс између лажних позитива и лажних негатива. Коначна процена врши се на независном тест скупу, уз детаљан classification report по класама (ham / spam).
8. **Репродуцибилност** Ради поновљивости експеримента фиксиран је random seed (вредност 42), чиме се контролише иницијализација и редослед обраде података током тренинга.

Параметри машина на којој је модел трениран


Компонента	Вредност
OS	Microsoft Windows 11 Pro
Процесор	Intel Core Ultra 7 155H (16 jezgara, 22 logička)
RAM	64 GB
Графика	Intel Arc Pro Graphics
PyTorch	2.12.0+cpu
CUDA	Није коришћена (cuda_available=False)
Уређај за тренинг	CPU

Параметри тренинга


Параметар	Вредност
Model	Encoder transformer
Архитектура	d_model=128, 2 encoder блока, 4 главе, FFN=512, dropout=0.1
Dataset	METHOS-dataset-spam
Train/Val/Test	60.982/13.166/13.128
Tokenizator	Word level
Број епоха	15
Batch size (train)	64
Batch size (eval)	128
Learning rate	$3 * 10^{-4}$
Weight decay	0.01
Оптимизатор	AdamW
Loss	Cross-entropy
Seed	42
Eval/ save стратегија	По епохи
Избор најбољег модела	По F1
Укупно корака	953
Најбољи checkpoint	епоха 2
Најбољи validation F1	0.9889

Резултати

Графици loss-а и метрика за тренинг и валидацију




Слика 1. Train loss по кораку




Слика 2. Validation loss по епохи

Slika 3. Train vs validation loss



Слика 3. Train vs validation loss


Slika 4. Accuracy, Precision, Recall, F1




Слика 4. Accuracy, Precision, Recall, F1

Током тренинга, вредност функције губитка на тренинг скупу брзо опада већ у првој епохи (са ≈ 0.088 на знатно ниже вредности у наредним епохама), што указује на успешну конвергенцију модела. Validation loss је најнижи већ у првој епохи (≈ 0.0385), а у другој остаје сличан (≈ 0.040), док од треће епохе надаље расте (нпр. ≈ 0.054 у епохи 3, касније и преко 0.08), што указује на почетак благог претераног прилагођавања (overfitting). Validation метрике (accuracy, precision, recall и F1) достижу максимум у другој епохи (F1 ≈ 0.9889). На основу F1 резултата као критеријума за избор модела, задржан је модел из друге епохе, који је потом евалуиран на независном тест скупу (accuracy ≈ 0.9890 , macro F1 ≈ 0.9890).

Вредности метрика на тест скупу



Слика 5. Precision, Recall, F1 за хам и спам



Слика 6. Асцурасу + масгро метрике

На независном тест скупу од 13.128 порука модел је постигао тачност од 98.90%, уз готово идентичне вредности макро precision, recall и F1 метрика ($\approx 98.90\%$). Перформансе по класама су уравнотежене: F1 резултат за ham износи приближно 98.91%, а за spam приближно 98.90%, што показује да модел поуздано разликује обе класе без значајне пристрасности. Ови резултати потврђују да encoder transformer трениран од нуле добро генерализује и на подацима који нису коришћени током тренинга.

Опис резултата

Тренинг encoder transformer модела од нуле на MENTHOS-dataset-spam скупу података дао је високе перформансе како на валидационом, тако и на тест скупу. Током тренинга, функција губитка на тренинг скупу брзо опада већ у првој епохи, што указује на успешну конвергенцију. Validation loss је најнижи у првој епохи (≈ 0.0385), у другој остаје сличан, а од треће епохе надаље расте, што указује на благи overfitting. Validation метрике (accuracy, precision, recall и F1) достижу максимум у другој епохи ($F1 \approx 0.9889$). Као најбољи модел задржан је checkpoint из друге епохе, изабран на основу F1 резултата.

На независном тест скупу од 13.128 порука модел је постигао тачност од 98.90%. Макро precision, recall и F1 такође износе приближно 98.90%, што показује уравнотежен однос између тачних позитивних и обухваћених spam порука. По класама, F1 резултат за ham ($\approx 98.91\%$) и spam ($\approx 98.90\%$) скоро је идентичан, па модел нема значајну пристрасност према једној класи. Ови резултати потврђују да encoder трансформер архитектура, тренирана од нуле (без pretrained модела и fine-tuninga), ефикасно решава проблем бинарне класификације SMS/email порука.

Закључак

У овом раду реализован је систем за детекцију spam порука заснован на encoder transformer архитектури тренираној од нуле, на MENTHOS-dataset-spam скупу података. Примењени приступ — WordLevel токенизација, encoder репрезентација са mean pooling-ом и класификационим слојем, уз оптимизацију cross-entropy губитком — показао је високу тачност и стабилне метрике на тест скупу (accuracy и макро F1 $\approx 98.90\%$). Добијени резултати указују да и модел без pretrained тежина може успешно да реши задатак детекције нежељених порука, уз пажљив избор најбољег checkpoint-a по validation F1 због благог overfitting-a у каснијим епохама.