

УНИВЕРЗИТЕТ У БЕОГРАДУ
ЕЛЕКТРОТЕХНИЧКИ ФАКУЛТЕТ



ПРОЈЕКТНИ ЗАДАТАК : Детекција нежељених СМС порука

Професор:

доц. др Стефан Тубић

ас. мс Матија Додовић

Студент:

Данило Дробњак

2025/3272

Опис проблема

Овај рад истражује проблем аутоматске детекције *spam SMS* порука на енглеском језику. Циљ је направити модел који одређује да ли је порука легитимна или нежељена/*spam*, на основу текстуалног садржаја поруке, што се моделује као задатак бинарне класификације текста. За решавање се користи енкодер трансформер архитектура која моделира семантичко значење речи у контексту и на основу тога доноси одлуку о класи поруке.

Скуп података

За овај рад користиће се скуп података *MENTHOS-dataset-spam*, који је доступан на платформи *Hugging Face*:

<https://huggingface.co/datasets/LHRS-UM-FERI/MENTHOS-dataset-spam>

Скуп података садржи око 87.000 текстуалних порука подељених на тренинг, валидациони и тест подскуп. Тренинг подскуп садржи 60.982 примера, валидациони 13.166, а тест 13.128. Сваки пример садржи текст поруке (*text*) и бинарну лабелу (*label*), где 0 означава легитимну поруку (*ham*), а 1 нежељену/*spam* поруку. Подаци су формирани спајањем јавно доступних извора *SMS* и *email spam* порука, а сваки подскуп је уравнотежен између две класе, чиме је погодан за бинарну класификацију.

Методe за решавање проблема

Проблем детекције *spam SMS* порука решава се коришћењем трансформер архитектуре засноване на енкодеру. Улазни текст, који представља садржај *SMS* поруке, прво се токенизује, а затим прослеђује енкодеру који моделује значење речи у контексту. На излазу енкодера додаје се класификациони слој који доноси коначну одлуку да ли је у питању легитимна (*ham*) или нежељена (*spam*) порука. Модел се тренира коришћењем *cross-entropy* функције губитка, а успешност модела процењује се на основу тачности и *F1* резултата.